Атлас

Текст продуктового брифа · к слайдам 1-2

1. Задача бизнеса и пользователь

Мы работаем над решением для автоматического заполнения характеристик товаров. Модель берёт название, описание и параметры продавца и превращает их в структурированные значения.

У каждого извлечённого значения есть подтверждение: цитата из исходного текста.

Основной пользователь - контент-менеджер товарного каталога. Сейчас он вручную переносит данные и исправляет разнобой в характеристиках. Наша задача - сократить эту ручную работу.

Мы распределили задачу между участниками команды: каждый разрабатывает свой подход. Затем сравним результаты и выберем самый экономичный вариант, который обеспечивает нужное качество.

2. Требования к результату

Решение должно учитывать четыре основных требования.

1. **Разные входные данные.** Таблицы CSV и JSON, текстовые файлы TXT или просто вставленный текст.
2. **Единый формат.** Набор характеристик зависит от категории товара. Названия, типы значений и единицы измерения должны быть едиными.
3. **Проверяемость.** Каждое извлечённое значение связано с цитатой. Оценка уверенности модели помогает определить, что проверить, но не гарантирует правильный ответ.
4. **Работа с неопределённостью.** Если данных нет, поле остаётся пустым. Расхождения между источниками решает человек.

3. Основной сценарий решения

К слайдам 3-5

Приём данных

Сценарий начинается с загрузки. Есть два режима.

Партия товаров: загружаем CSV или JSON, смотрим предпросмотр и сопоставляем колонки. Система показывает ошибки, которые нужно исправить.

Один товар: загружаем TXT или вставляем текст. На экране пример с чайником Tefal: система предложила название, категорию и нашла все шесть характеристик.

Рядом с каждым значением видно, из какого фрагмента текста оно взято. Пользователю остаётся проверить черновик и создать карточку.

Сравнение четырёх подходов

Для извлечения характеристик мы рассматриваем четыре подхода: правила и словари, классическую модель NER на CRF, трансформер и LLM. Они отличаются не только качеством, но и стоимостью работы.

Чтобы сравнение было честным, проверим все подходы на одних и тех же карточках, по одной схеме характеристик и одинаковым правилам оценки.

> **Выберем метод или их комбинацию с минимальной полной стоимостью среди вариантов, которые проходят порог качества.**

В полную стоимость включаем вычисления, ручную проверку, обучение и поддержку. Общего победителя пока нет, LLM находится в разработке.

Каталог и очередь проверки

В каталоге есть поиск по товару, бренду или артикулу и фильтры по категории и статусу карточки.

Сначала показываются конфликты и спорные значения - то, что действительно требует внимания человека. Новые товары можно обрабатывать массово.

3. Проверка и подготовка результата

Продолжение основного сценария · к слайдам 6-8

Решение по цитате

Например, в описании указано 4 ГБ оперативной памяти, а в параметрах продавца - 5 ГБ.

Система показывает оба варианта и оба источника. Сотрудник сверяет данные, затем принимает значение или вносит исправление.

Можно отдельно отклонить неверный вариант или подтвердить, что характеристики в тексте нет. Это разные ситуации, и система их различает.

Нормализация значений

Одно и то же значение в текстах записывают по-разному. Например, объём может быть указан в миллилитрах или литрах, а единицы - записаны как «мл», «ml», «л» или «литра».

Словари приводят значения к единице каталога: 1700 мл сохраняется как 1,7 л. Аналогично объединяются варианты написания цветов, брендов и материалов.

Справа на экране видно, что правило можно проверить на любом фрагменте текста ещё до применения к каталогу.

Выгрузка и контроль

На выходе получаем готовые карточки в CSV или JSON для загрузки в товарную систему. Для каждого значения сохраняется, как оно получено: принято автоматически, подтверждено или исправлено человеком.

Отдельно есть аналитика: размер очереди, частые исправления и доля автоприёма. Ручная правка не засчитывается как автоматическое решение. По этой статистике видно, какие категории стоит улучшать дальше.

4. Главная ценность: проверка вместо ручного ввода

К слайду 9

Контент-менеджер меньше вводит руками, видит цитату у каждого значения и сосредотачивается на спорных полях.

Для бизнеса это больше товаров с заполненными характеристиками для поиска и фильтров и более быстрая подготовка карточек к публикации. Правила и CRF можно запускать на обычных процессорах. Более дорогие модели будем выбирать там, где дополнительное качество оправдывает затраты.

Три цифры из имеющихся замеров. Точность извлечения CRF на новых карточках составляет **0,943**. При разборе найденных расхождений **28%** оказались ошибками в самом каталоге. Значит, система может помогать и в очистке существующих данных. Обработка каталога в текущем замере занимает **около часа на одном ядре процессора**.

Эти результаты относятся к отдельным замерам и пока не определяют победителя среди четырёх подходов. Экономию времени менеджеров измерим в пилоте.

5. Критерии выбора и успеха

К слайду 10

Чтобы понять, работает ли решение, сравним подходы на одном эталоне с ручной проверкой и по одинаковым правилам. Смотрим пять показателей:

1. **Качество извлечения** по F1, в том числе по отдельным категориям.
2. **Надёжность автоприёма.** Предлагаем порог: правильность автоматически принятых значений не ниже 98%.
3. **Доля автоматизации:** сколько применимых полей система принимает без участия человека.
4. **Скорость:** время обработки и ручной проверки карточки.
5. **Полная стоимость** за тысячу готовых карточек, включая вычисления, труд людей, обучение и поддержку.

В итоге выбираем самый экономичный вариант, который проходит пороги качества и скорости.